

MATEMATIČKI FAKULTET

RAČUNARSKA INTELIGENCIJA

**Primena genetski algoritama i neuralnih  
mreža pri učenju autonomnih vozila**

*Student*

Ivan Milutinović 180/2021

*Asistent*

Stefan Kapunac

Beograd, 27. septembar 2024.

# Sadržaj

<b>1</b>	<b>Uvod</b>	<b>2</b>
<b>2</b>	<b>Problem</b>	<b>3</b>
<b>3</b>	<b>Rešenje problema</b>	<b>4</b>
3.1	Prva iteracija . . . . .	4
3.2	Druga iteracija . . . . .	4
<b>4</b>	<b>Rezultati</b>	<b>5</b>
4.1	Rezultati više populacija . . . . .	5
4.2	Rezultati jedne populacije . . . . .	7
4.2.1	Bez pomoćnih metoda . . . . .	7
4.2.2	Intenzifikacija mutacije . . . . .	7
<b>5</b>	<b>Zaključak</b>	<b>8</b>
	<b>Literatura</b>	<b>8</b>

# 1 Uvod

U savremenom istraživanju autonomnih vozila, ključni izazov je omogućiti automobilima da se samostalno kreću po specifičnoj stazi sa što većom preciznošću i efikasnošću. Ovaj problem se često modeluje kao kompleksan zadatak optimizacije, gde cilj nije samo da automobil nauči osnovne veštine vožnje, već da razvije sofisticirane sposobnosti za navigaciju kroz dinamično okruženje. U ovom kontekstu, upotreba neuralnih mreža i genetskih algoritama predstavlja inovativan pristup za postizanje autonomnih veština.

Neuralne mreže, koje su inspirisane načinom na koji ljudski mozak obrađuje informacije, mogu se koristiti za modelovanje složenih funkcija koje definišu ponašanje automobila. Svaka neuralna mreža predstavlja jedan model ponašanja automobila, a njena sposobnost da autonomno upravlja vozilom zavisi od njenih parametara i strukture. Međutim, pronalaženje optimalnih parametara i arhitekture mreže može biti izuzetno izazovno zbog visokog nivoa složenosti i nelinearnosti problema. U knjizi "Genetic Algorithms for Optimization of Neural Network Structures and Parameters" (Goldberg, 1989) [1] se predstavlja osnovni rad o genetskim algoritmima za optimizaciju strukture i parametara neuralnih mreža. Autor detaljno opisuje kako genetski algoritmi mogu poboljšati performanse neuralnih mreža u složenim problemima, uključujući prilagođavanje težina i arhitekture mreže.

Jedan od značajnih doprinosa u ovoj oblasti ima metoda "Augmented Topologies" [2] (NEAT) koju su razvili Kenneth O. Stanley i Risto Miikkulainen (2009). NEAT koristi genetske algoritme za evoluciju neuralnih mreža sa promenljivim topologijama. Ova metoda omogućava automatsko prilagođavanje strukture mreže tokom procesa učenja, što značajno unapređuje sposobnosti neuralnih mreža u rešavanju kompleksnih zadataka kao što je autonomna vožnja.

## 2 Problem

Prvo ćemo da malo detaljnije opišemo genetski algoritam radi boljeg razumevanja primene algoritma na problem kojim se bavimo. Genetski algoritmi su inspirisani prirodnim procesima evolucije i selekcije i koriste se za rešavanje kompleksnih optimizacionih problema kroz simulaciju prirodne selekcije. Temeljni princip genetskog algoritma je da se evolucionim procesima koriste za pronalaženje optimalnih rešenja u složenim prostorima pretrage. Ovaj algoritam obuhvata nekoliko ključnih koraka koji odražavaju prirodne procese u biološkoj evoluciji: selekciju, ukrštanje i mutaciju.

U koraku selekcije biraju se najuspešniji pojedinci (rešenja) iz populacije na osnovu njihovih performansi u odnosu na ciljnu funkciju. Najbolji pojedinci imaju veće šanse da prenesu svoje osobine (gene) na sledeću generaciju. Selekcija se često vrši prema principu “prirodne selekcije”, gde su pojedinci sa boljim rezultatom favorizovani. Proces ukrštanja uključuje kombinovanje genetskih materijala dva ili više roditeljskih rešenja kako bi se stvorila nova potomstva.

Ukrštanje omogućava stvaranje novih rešenja koja kombinuju karakteristike uspešnih roditeljskih rešenja, potencijalno nudeći poboljšanja u odnosu na prethodne generacije. Da bi se omogućila dodatna raznovrsnost i istraživanje novih mogućnosti, genetski algoritmi primenjuju mutaciju, koja uključuje nasumične promene u genetskom materijalu pojedinca.

Mutacija pomaže u prevazilaženju lokalnih optimuma i istraživanju novih oblasti prostora pretrage. Proces se ponavlja kroz generacije, pri čemu se populacija kontinuirano razvija i poboljšava. Svaka nova generacija nastoji da poboljša performanse prethodnih generacija kroz kombinaciju selekcije, ukrštanja i mutacije, dok se ciljna funkcija koristi za ocenjivanje i usmeravanje procesa optimizacije.

## 3 Rešenje problema

Pri rešavanju datog problema su korišćeni različiti pristupi od čega je vredno spomenuti dva načina rešavanja kako bi se bolje prikazao efekat primene neuralnih mreža.

### 3.1 Prva iteracija

Prva iteracija algoritma se zasnivala na tome da se za jedinke koristi konačna lista instrukcija (napred, levo, desno) i genetskim algoritmom usavrši niz komandi koje auto treba da izvrši (60 komandi u sekundi). Mana ovog pristupa je što bi jedinka naučila da se kreće samo po određenoj stazi i ukoliko bi se staza promenila ceo proces bi morao da se ponovi kako bi se dobilo novo rešenje prilagođeno za novu stazu. Pored toga proces je previše spor jer se u suštini isprobavaju sve moguće permutacije komandi.

### 3.2 Druga iteracija


Druga iteracija algoritma koristi numpy biblioteku za realizovanje računanja izlaznih vrednosti neuralnih mreža. Rešenje je po uzoru na metodu "Augmented Topologies"(NEAT). Ideja rešenja je da se pomoću procesa genetskog algoritma, neuralne mreže (jedinke) poboljšavaju menjanjem parametara neurona i povećavanjem ili smanjivanjem broja neurona po slojevima. Proces selekcije se vrši tako što se nasumično odabere određeni broj jedinki i sačuvaju dve najbolje jedinke (turnirska selekcija). Nakon toga se uzima jedan deo slojeva prve neuralne mreže i nadovezuje se (ukrštanje) na drugi deo slojeva drugog roditelja i obrnuto čime dobijamo dva deteta. Prvi deo procesa mutacije predstavlja prolaženje kroz sve parametre neurona i sa određenom šansom se povećava ili smanjuje vrednost parametra. U drugom delu mutacije može doći do menjanja (povećavanja ili smanjivanja) broj neurona na nasumično odabranom sloju mreže što dovodi do menjanja strukture mreže. Funkcija cilja je predjeni put auta u određenom vremenskom periodu što znači da se teži što većoj srednjoj brzini auta. Pored toga se računa odnos levog i desnog radara koji predstavlja koliko je auto udaljen od leve i desne ivice čime želimo da postignemo da se auto nalazi što bliže sredini staze kako bi se sprečilo da auto koji se kreće uz ivicu ima veću vrednost funkcije cilja (predjeni put veći je veći ali je manje staze obišeno). Ulazne vrednosti jedne neuralne mreže su dužine radara (pet radara postavljenih na 45 stepeni razmaka) od sredine vozila do ivice staze i to je sve što jedna jedinka "vidi". Izlazne vrednosti predstavljaju komande nad vozilom (pravo, levo, desno, pusti gas, koči) gde mreža daje komandu koja bi najverovatnije trebala da se izvrši.

## 4 Rezultati

U ovom delu se predstavljaju dobijeni rezultati dobijeni kroz testiranje rešenja. Podešavanje funkcije cilja i funkcija za računanje verovatnoće mutacija su dobijene kroz mnogobrojna pokretanja programa i biranja onih koje su dale najbolje rezultate.


### 4.1 Rezultati više populacija

Na sledećoj slici je prikazana vrednost funkcije cilja kroz generacije (epohe) populacije. Kao što možemo da vidimo sve populacije su imale makar jednu jedinku koja je uspela da nauči da se kreće po stazi sve vreme. Nagli usponi u funkciji cilja predstavljaju trenutke u kojima su jedinke naučile da skrenu levo tj. desno, nakon čega mogu da primene naučeno ponašanje na druge krivine i samim tim savladaju najteže delove učenja.




Slika 1: Rezultati 10 populacija koje su prošle kroz 50 generacija.

Sledeći graf predstavlja učestalost struktura mreža najboljih jedinki populacija. Imajući u vidu da su sve populacije imale makar jednu jedinku koja je naučila da vozi možemo da primetimo da je i početna struktura tj. minimalna struktura je dovoljna da bi jedinka naučila da vozi što nam govori da sam problem koji je zadat jedinkama nije toliko težak. Očekivano je da vidimo da ima veći broj kompleksnijih struktura pošto je funkcija verovatnoće mutacije strukture agresivna funkcija koja će biti objašnjena u narednom delu rada.




Slika 2: Strukture najboljih jedinki u 10 populacija

Zeleni neuroni su ulazni sloj koji predstavlja dužine radara jednog vozila. Roze neuroni su izlazni sloj. Neuroni između ova dva sloja su članovi skrivenih slojeva koji imaju svoje težine nad kojim se vrše mutacije. Za krajnju mrežu je uzeta najčešće dobijena struktura mreže iz prethodnog merenja.



(a) Početna mreža



(b) Krajnja mreža

Slika 3: Rezultati jedne populacije sa intenzifikacijom mutacije

## 4.2 Rezultati jedne populacije


U nastavku će biti prikazani rezultati dobijeni nad jednom populacijom, gde su prikazane neke metode koje su korišćene kako bi se savladale poteškoće pri učenju autonomnih vozila i kako bi se postigle što veće performanse jedinke.

### 4.2.1 Bez pomoćnih metoda

Na levoj slici plava linija predstavlja najbolju jedinku, dok druga linija predstavlja srednju vrednost funkcije cilja cele populacije. Generalno rastuće ponašanje srednje vrednosti funkcije cilja je očekivano jer se verovatnoća mutacije smanjuje i jedinke sve više oponašaju neke od najboljih jedinki čime se srednja vrednost približava najboljoj vrednosti funkcije cilja te populacije. Na desnoj slici su prokazane funkcije verovatnoće mutacije. Plava linija predstavlja funkciju verovatnoće mutacije za težine neuralne mreže, a narandžasta linija predstavlja mutaciju za menjanje broja neurona u strukturi neuralne mreže.

Prva funkcija je jednostavna i predstavlja smanjivanje verovatnoce mutacije kroz broj epoha čime se postiže velika raznolikost jedinki na početku i skoro nikakva razlika pojedinaca na kraju.

Druga funkcija predstavlja zavisnost mutacije u odnosu na vreme jedne epohe u smislu da se gleda koliko je najduže bila živa jedinka populacije. Ukoliko se jedinka (koja je najduže bila živa) odmah sudarila sa ivicom staze pretpostavljamo da želimo da mutacija bude agresivna, a ako je to vreme bilo dugo ili jednako maksimalnom dozvoljenom vremenu onda je mutacija jednaka nuli i ne želimo da menjamo samu strukturu neuralnih mreža pošto je cilj da dobijemo najmanju moguću strukturu. Možemo da primetimo vezu između vrednosti funkcije cilja najbolje jedinke (na levoj slici plava linija) i verovatnoće mutacije strukture mreže (desna slika narandžasta linija), u trenutku kada je jedinka uspela da se ne sudari sa ivicama staze tada je verovatnoće menjanja strukture postala nula i nastavljamo samo sa mutacijom težina mreže.




Slika 4: Rezultati jedne populacije

### 4.2.2 Intenzifikacija mutacije

Na ovim grafovima se prikazani isti parametri kao i na prošlim sa tim što je ovde primenjena metoda intenzifikacije mutacije. Metoda predstavlja način



prevazilaženja lokalnih ekstremuma (u ovom slučaju maksimum) tako što povećava verovatnoću mutacije populacije i na taj način pokušava da uz pomoć povećanog diverziteta dobije jedinku koja će savladati taj ekstremum nakon čega se verovatnoća mutacije vraća u normalu. Najbolji rezultati su dobijeni primenom metode samo nad mutacijom težina neuralne mreže.



Slika 5: Rezultati jedne populacije sa intenzifikacijom mutacije

## 5 Zaključak

Dobijeni rezultati prikazuju efekat primene genetskog algoritma nad optimizacijom neuralnih mreža. Zanimljiv deo jeste manipulacija same strukture neuralne mreže i dobijanje što prostije strukture kako bi bio savladan problem. Kad je u pitanju optimizacija samih parametara tj. težina neuralnih mreža mnogo bolji rezultati bi bili dobijeni primenom gradijnata. Ideja za sledeću iteraciju jeste kombinacija gradijenta i genetskog algoritma gde će gradijent biti upotrebljen za optimizaciju parametara mreža, a genetski algoritam biti zadužen za mutaciju strukture mreže. Pored toga, kako bi se bolje prikazala moć ovog rešenja neophodno je napraviti kompleksniji problem u vidu prepreka na putu ili različitih podloga staze sa različitim trenjima.

## Literatura

- [1] Goldberg. *Genetic Algorithms for Optimization of Neural Network Structures and Parameters*. 1989.
- [2] Kenneth O. Stanley and Risto Miikkulainen. *Evolving Neural Networks through Augmenting Topologies*. The MIT Press.